

Projet Algorithmique 3 — Distance de Jaccard

Identifiant : 22313078

Nom : YOUSFI

Prénom : Kenza

Date : 11 Mai 2025

Groupe : TP3

1. Objectif du projet

Ce projet a pour but de calculer la distance de Jaccard entre les ensembles de mots contenus dans des fichiers textes. Il doit supporter différentes options en ligne de commande et utiliser une structure de données efficace, ici une table de hachage.

2. Description des modules

 main.c

Contient le point d'entrée du programme. Gère l'analyse des options, la lecture des fichiers et l'affichage des résultats.

 hashtable.[c|h]

Implémente une table de hachage générique. Fournit les opérations de base : insertion, recherche, parcours.

 holdall.[c|h]

Permet de stocker une collection d'éléments génériques. Sert à manipuler les ensembles de mots.

 lecture.[c|h]

Lecture des fichiers texte et extraction des mots selon les options (-p, -iN, -i N) ou (--punctuation-like-space, --initial=N, --initial N).


 distance.[c|h]

Contient les fonctions de calcul de la distance de Jaccard entre ensembles.

 graph.[c|h]

Affiche le graphe des mots en mode tabulaire lorsque l'option (-g, --graph) est activée.

3. Schémas explicatifs



4. Résultat valgrind

```
yousfi@yousfi-Latitude-7490:~/L2 Informatique/ALGO 3/PROJET/jaccard$ valgrind --leak-check=full --show-leak-kinds=all
./jdis a.txt b.txt
==12656== Memcheck, a memory error detector
==12656== Copyright (C) 2002-2022, and GNU GPL'd, by Julian Seward et al.
==12656== Using Valgrind-3.22.0 and LibVEX; rerun with -h for copyright info
==12656== Command: ./jdis a.txt b.txt
==12656==
0.7778 a.txt b.txt
==12656==
==12656== HEAP SUMMARY:
==12656== in use at exit: 0 bytes in 0 blocks
==12656== total heap usage: 79 allocs, 79 frees, 15,475 bytes allocated
==12656==
==12656== All heap blocks were freed -- no leaks are possible
==12656==
==12656== For lists of detected and suppressed errors, rerun with: -s
==12656== ERROR SUMMARY: 0 errors from 0 contexts (suppressed: 0 from 0)
```

5. Exemples d'utilisation

- Commande : `./jdis a.txt b.txt`

Sortie : 0.9000 a.txt b.txt

Explication : Calcule la distance de jaccard sans rien appliquer sur les mots.

- Commande : `./jdis -p a.txt b.txt || ./jdis --punctuation-like-space a.txt b.txt`

Sortie : 0.6250 a.txt b.txt

Explication : Rends les signes de ponctuation comme des espaces.

- Commandes : `./jdis -i3 a.txt b.txt || ./jdis -i 3 a.txt b.txt || ./jdis -initial=3 a.txt b.txt`

Sortie : cut: a.txt:1: chat...

cut: a.txt:1: chien...

cut: a.txt:1: souri...

cut: a.txt:2: pomme...

cut: a.txt:2: banan...

cut: a.txt:3: froma...

cut: b.txt:1: chien...

cut: b.txt:1: tigre...

cut: b.txt:2: banan...

cut: b.txt:2: orang...

cut: b.txt:3: chat!...

0.6250 a.txt b.txt

Explication : tronque les mots à la taille 3 puis calcule la distance.

- Commande : `./jdis -g a.txt b.txt || ./jdis --graph a.txt b.txt`

Sortie : a.txt b.txt

banane - x

banane. x -

chat x -

chat!!!! - x

chien	x	x	
fromage		x	-
orange	-	x	
pomme	x	-	
souris	x	-	
tigre	-	x	

Explication : Affiche l'appartenance de chaque mot dans un fichier

6. Limitations

- Pour éviter d'avoir des fuites mémoires quand on utilise plusieurs fichiers, j'ai limité le nombre de fichiers à 64.